

컴퓨터비전_인공지능(AI)개론

15. 사용자 데이터 분류

- 문제 정의하기
- 데이터 준비
- 파인 튜닝의 경우
- 전이 학습의 경우
- 사용자 정의 데이터를 사용하는 경우

실제 업무에서는 JPEG 형식과 같은 이미지 데이터를 직접 다루어야 합니다. 파이토치의 ImageFolder 기능을 활용하면 데이터셋 지정 부분만 변경하고 나머지 학습 코드는 그대로 사용할 수 있습니다.

ImageFolder는 특정 트리 구조로 배치된 이미지 파일을 머신러닝의 입력 데이터로 자동 변환합니다. 폴더 이름을 라벨로 인식하고 해당 폴더 안의 이미지들을 데이터로 사용하여 파이토치 데이터셋을 생성합니다.

필수 구조 요구사항

ImageFolder를 사용하기 위해서는 학습 데이터를 특정 트리 구조로 배치해야 합니다.

train 폴더와 val(검증) 폴더를 만들고,
각 폴더 아래에 분류하려는 클래스 이름으로 하위
폴더를 생성합니다.

```
- `root/`  
  - `train/`  
    - `ants/`  
      - `0013035.jpg`  
      - `1030023514_aad5c608f9.jpg`  
      - ...  
    - `bees/`  
      - `1092977343_cb42b38d62.jpg`  
      - ...  
  - `val/`  
    - `ants/`  
      - `10308379_1b6c72e180.jpg`  
      - ...  
    - `bees/`  
      - `1032546534_06907fe3b3.jpg`  
      - ...
```



검증 데이터 전처리

- Resize(256): 이미지 크기 조절
- CenterCrop(224): 중앙 잘라내기
- ToTensor(): 텐서 변환
- Normalize: 정규화

사전 학습된 모델이 224x224 크기로 학습되었기 때문에 일관된 평가를 위해 항상 이미지의 중앙부를 사용합니다.



훈련 데이터 전처리

- RandomResizedCrop(224): 무작위 크기 조절 및 자르기
- RandomHorizontalFlip: 무작위 좌우 반전
- RandomErasing: 무작위 영역 지우기

데이터 증강 기법을 사용하여 모델이 매번 조금씩 다른 이미지를 학습하게 함으로써 과대적합을 방지하고 일반화 성능을 높입니다.

ImageFolder로 데이터셋 생성

디렉터리 경로를 지정하고 ImageFolder를 호출하여 데이터셋을 만듭니다.

개미(ants)와 벌(bees)을 분류하는 예제에서는 훈련 데이터 244건, 검증 데이터 153건으로 구성됩니다.

244

**훈련
데이터**

데이터 증강이
적용된 학습용
이미지

153


**검증
데이터**

모델 성능 평가용
이미지

2

**분류
클래스**

개미(ants)와
벌(bees)



DataLoader는 배치 크기 10으로 설정하여 모델 훈련 시 데이터를 효율적으로 공급합니다.

훈련 시에는 shuffle=True로 설정하여 매 epoch 마다 데이터 순서를 섞어 모델이 데이터 순서를 학습하는 것을 방지합니다.

파인 튜닝은 사전 학습된 모델의 모든 파라미터를 우리의 데이터에 맞게 미세 조정하는 방식입니다.

VGG-19-BN 모델을 사용하여 개미와 벌 분류 모델을 학습합니다.

01

사전학습모델 불러오기

VGG-19-BN 모델을 학습이 끝난
파라미터와 함께 불러옵니다

03

최적화 함수 설정

모델의 모든 파라미터를
업데이트 대상으로 지정합니다

02



최종 계층 수정

분류 클래스가 2개이므로
최종 노드의 출력을 2로 변경합니다

04

학습 진행

5 에포크 동안 학습을 진행하여
모델을 미세 조정합니다



5 에포크 학습 후 검증 정확도 96.08%를 달성했습니다. 훈련 정확도는 94.26%로 과대적합 없이 안정적인 성능을 보였습니다.

전이 학습은 사전 학습 모델의 대부분의 가중치는 그대로 두고(동결), 마지막 분류 계층만 새로 학습하는 방식입니다.
학습 데이터가 매우 적을 때 더 효과적입니다.



가중치 동결

모든 파라미터의 `requires_grad`를
False로 설정하여 기존 학습된 가중치가
업데이트되지 않도록 동결합니다



최종 계층 교체

마지막 분류 계층만
새로운 Linear 계층으로 교체하여
2개 클래스 분류에 맞게 조정합니다



선택적 학습

옵티마이저에 최종 계층의 파라미터만
전달하여 해당 계층만 학습되도록 합니다

전이 학습 결과 역시 약 96%의 정확도를 보여, 이번 예제에서는 파인 튜닝과 동일한 성능을 기록했습니다.

파인 튜닝

- 모든 파라미터 업데이트
- 더 많은 학습 데이터 필요
- 학습 시간이 더 오래 걸림
- 데이터가 충분할 때 효과적

전이 학습

- 최종 계층만 업데이트
- 적은 데이터로도 학습 가능
- 학습 시간이 짧음
- 데이터가 적을 때 효과적

일반적으로 학습 데이터가 적을수록 전이 학습이 더 좋은 성능을 내는 것으로 알려져 있습니다.

▶ 데이터가 적고 분류가 어려운 사례 : 시베리안 허스키 vs 늑대

수집한 시베리안 허스키와 늑대 이미지로 더 어려운 분류 문제에 도전합니다. 두 동물은 외형이 매우 유사하여 분류가 까다롭습니다.

극소량 데이터

훈련 데이터 40장, 검증 데이터 10장으로
매우 적은 데이터셋입니다

전이 학습 적용

데이터 수가 매우 적으므로
전이 학습 방식이 적합합니다

데이터 증강 강화

RandomHorizontalFlip과
RandomErasing을 추가하여
데이터 부족 문제를 완화합니다

배경이 상당 부분 제거된 이미지를 사용하므로 224x224 크기로 바로 리사이즈합니다.

배치 사이즈는 데이터 양이 적어 5로 설정합니다.

▶ 허스키-늑대 분류 학습 결과

Epoch 1 — 1

훈련 정확도 65%,
검증 정확도 100%

2 — Epoch 2



훈련 정확도 85%,
검증 정확도 90%

Epoch 9 — 3

훈련 정확도 100%,
검증 정확도 100%

4 — Epoch 10 (최종)

훈련 정확도 92.5%,
검증 정확도 100%



검증 데이터 10장 모두를 정확하게 분류하는 완벽한 성능을 보였습니다.
전이 학습이 극소량 데이터에서도 효과적임을 입증했습니다.

ImageFolder 활용

특정 디렉터리 구조만 준수하면 자동으로 데이터셋을 생성하여 실무에서 빠르게 적용 가능합니다

데이터 증강의 중요성

RandomErasing, RandomHorizontalFlip 등의 기법으로 적은 데이터로도 높은 성능을 달성할 수 있습니다

전이 학습

데이터가 적을 때는 전이 학습이 파인 튜닝보다 효과적이며, 40장의 극소량 데이터로도 100% 정확도를 달성했습니다

사전 학습된 모델과 적절한 학습 전략을 선택하면 실무에서 마주하는 다양한 이미지 분류 문제를 효과적으로 해결할 수 있습니다. 데이터의 양과 특성에 따라 파인 튜닝과 전이 학습 중 적절한 방법을 선택하는 것이 중요합니다.