

컴퓨터비전_인공지능(AI)개론

17.자연어처리_NLP/종합실습

▶ 자연어처리 / 종합실습

- 텍스트 전처리 이해: 토큰화, 패딩, 임베딩
- LSTM 구현: 순환 신경망 활용한 감성 분류 모델 구현
- DistilBERT 파인튜닝: 사전학습된 Transoformer 모델 적용
- 모델 비교 분석

▶ 정의와 핵심 개념

- 자연어 처리는 인간의 언어와 딥러닝을 연결하는 학문 분야입니다. 컴퓨터가 텍스트를 이해하고 생성하며 의미 있는 작업을 수행할 수 있도록 합니다

주요 작업 영역

- 토큰화 (Tokenization): 문장을 단어 단위로 분리
- 품사 태깅 (POS Tagging): 각 단어의 문법적 역할 파악
- 개체명 인식 (NER): 인명, 지명 등 특정 개체 추출
- 감성 분석 (Sentiment Analysis): 텍스트의 긍정/부정 판단

실제 응용 분야

챗봇

고객 대응 자동화

검색 엔진

의미 기반 검색

기계 번역

다국어 소통 지원

원시 텍스트 데이터를 모델이 이해할 수 있는 숫자 형태로 변환하는 과정은 NLP의 핵심입니다.
데이터 정제 품질이 모델 성능에 직접적인 영향을 미친다



실제 예시

원본 텍스트: "I loved the movie!"

토큰화: [I, loved, the, movie, !]

정수 인코딩: [12, 45, 8, 99, 3]

패딩 적용: [12, 45, 8, 99, 3, 0, 0, 0]

원-핫 인코딩 vs 밀집 임베딩

원-핫 인코딩은 단어를 희소한 고차원 벡터로 표현하지만, 단어 간 의미적 관계를 포착하지 못합니다. 반면 밀집 임베딩은 저차원 공간에서 의미적으로 유사한 단어들을 가까운 위치에 배치합니다.

PyTorch의 nn.Embedding

학습 가능한 임베딩 레이어는 모델 학습 과정에서 자동으로 최적화되며, 작업에 특화된 단어 표현을 생성합니다. 임베딩 차원은 일반적으로 128, 256, 300 등을 사용합니다.

임베딩의 주요 특징:

- 의미적 유사성: 비슷한 단어들이 가까운 벡터 공간에 위치
- 차원 축소: 10,000 단어 어휘를 128차원으로 압축
- 관계 포착: "왕 - 남자 + 여자 = 여왕" 같은 의미 연산 가능

Long Short-Term Memory

LSTM은 순환 신경망의 일종으로, 장기 의존성 문제를 해결하기 위해 고안되었습니다. 기본 RNN이 겪는 기울기 소실 문제를 게이트 메커니즘을 통해 극복합니다.

세 가지 핵심 게이트

1. 입력 게이트 (Input Gate): 새로운 정보를 셀 상태에 얼마나 반영할지 결정
2. 망각 게이트 (Forget Gate): 기존 셀 상태에서 어떤 정보를 버릴지 선택
3. 출력 게이트 (Output Gate): 셀 상태에서 얼마나 출력할지 조절

LSTM의 장점

장기 기억

긴 문장의 맥락을 유지하며 처리 가능

기울기 안정성

깊은 시간 단계에서도 학습 가능

유연성

다양한 시퀀스 작업에 적용

LSTM은 시간에 따라 전개되며, 각 시간 단계에서 숨겨진 상태를 다음 단계로 전달합니다. 이를 통해 문장의 순차적 정보를 효과적으로 처리합니다.

임베딩 레이어

단어를 밀집 벡터로 변환 (예: 128차원)

선형 레이어

LSTM 출력을 클래스 개수에 맞게 변환

학습 설정

- 데이터셋: IMDb 영화 리뷰 (긍정/부정 레이블)
- 손실 함수: CrossEntropyLoss
- 옵티마이저: Adam (학습률 0.001)
- 배치 크기: 64
- 에포크: 3-5회

LSTM 레이어

시퀀스의 맥락 정보를 포착하여 숨겨진 상태 생성

소프트맥스

긍정(1) 또는 부정(0) 확률 출력

중요 고려사항

균형 잡힌 데이터셋이 중요합니다. 긍정과 부정 샘플이 비슷한 비율로 포함되어야 모델이 편향되지 않습니다.

패딩 마스크를 활용하면 실제 단어와 패딩 토큰을 구분하여 더 정확한 학습이 가능합니다.

RNN/LSTM의 한계

순환 신경망은 순차적으로 처리되므로 병렬화가 어렵고, 긴 텍스트에서 속도가 느립니다. 또한 거리가 먼 단어 간의 관계를 포착하는 데 한계가 있습니다.

LSTM의 제약사항

- 순차 처리로 인한 느린 학습 속도
- 고정된 은닉 상태 크기의 병목 현상
- 매우 긴 시퀀스에서의 정보 손실
- 병렬 연산 불가능

Transformer의 핵심 아이디어

Self-Attention 메커니즘은 문장의 모든 단어가 서로를 직접 참조할 수 있게 합니다. Query, Key, Value 벡터를 통해 각 단어의 중요도를 계산합니다.

Transformer의 장점

병렬 처리

모든 위치를 동시에 계산

장거리 의존성

거리에 관계없이 관계 포착

확장성

더 큰 모델 학습 가능

Attention은 문장에서 어떤 단어가 중요한지 가중치로 표현합니다. 예를 들어 "The cat sat on the mat"에서 "cat"과 "sat"의 관계를 강하게 연결합니다.

경량화된 Transformer 모델

DistilBERT는 원본 BERT의 40%만큼 작으면서도 성능은 97%를 유지하는 효율적인 모델입니다. 지식 증류(Knowledge Distillation) 기법을 통해 대형 모델의 지식을 압축했습니다.

아키텍처 특징

- 레이어 수: 6개 (BERT는 12개)
- 어텐션 헤드: 12개 유지
- 은닉 차원: 768 유지
- 파라미터: 약 66M개

입력 형식

[CLS] 텍스트 내용 [SEP]

[CLS] 토큰의 출력이 문장 전체의 표현으로 사용됩니다. 감성 분류 시 이 벡터를 분류 레이어에 입력합니다.

사전 학습과 파인튜닝

DistilBERT는 대규모 텍스트 코퍼스(Wikipedia, BookCorpus)에서 사전 학습되었습니다. 이 과정에서 언어의 일반적인 패턴을 학습했습니다.

파인튜닝 단계에서는 특정 작업(감성 분석)에 맞게 최종 레이어만 추가하고 전체 모델을 재학습합니다.

01

사전 학습

대규모 코퍼스에서 언어 이해 능력 습득

02

분류 헤드 추가

작업에 맞는 출력 레이어 부착

03

파인튜닝

레이블된 데이터로 전체 모델 재학습

04

평가 및 배포

검증 세트로 성능 확인 후 실전 적용

Bi-LSTM vs DistilBERT 성능 비교

모델	파라미터 수	학습 시간	정확도	추론 속도
Bi-LSTM	~2M	빠름 (20분)	~87%	매우 빠름
DistilBERT	~66M	중간 (45분)	~93%	중간
BERT-base	~110M	느림 (90분)	~95%	느림

Bi-LSTM의 장단점

장점:

- 구조가 단순하여 이해하기 쉬움
- 적은 메모리와 계산 자원 필요
- 빠른 학습 및 추론 속도
- 작은 데이터셋에서도 잘 작동

단점:

- 제한된 맥락 이해 능력
- 복잡한 언어 구조 포착 어려움
- 사전 학습의 이점 없음

DistilBERT의 장단점

장점:

- 강력한 맥락 이해 능력
- 사전 학습으로 적은 데이터로도 고성능
- Transfer Learning 활용 가능
- 다양한 NLP 작업에 적용 가능

단점:

- 더 많은 메모리와 계산 자원 필요
- 추론 속도가 상대적으로 느림
- 복잡한 구조로 디버깅 어려움

모델 선택은 프로젝트의 요구사항에 따라 달라집니다. 실시간 응답이 중요하다면 LSTM을, 최고 성능이 필요하다면 Transformer를 선택하세요. 속도와 정확도 사이의 균형을 고려하여 결정해야 합니다.



고객 피드백 모니터링

제품 리뷰와 고객 의견을 실시간으로 분석하여 긍정/부정 트렌드를 파악합니다. 부정적 의견에 신속하게 대응하여 고객 만족도를 높일 수 있습니다.



소셜 미디어 트렌드 분석

Twitter, Instagram 등의 게시물을 분석하여 브랜드 이미지와 여론을 추적합니다. 마케팅 캠페인의 효과를 측정하고 위기 상황을 조기에 감지합니다.



자동 리뷰 분류 시스템

전자상거래 플랫폼에서 수천 개의 리뷰를 자동으로 분류하고 요약합니다. 판매자는 제품 개선점을 빠르게 파악하고 마케팅 전략을 수립할 수 있습니다.



챗봇의 감정 인식

고객 응대 챗봇이 사용자의 감정 상태를 파악하여 적절한 대응을 제공합니다. 불만을 가진 고객을 담당자에게 연결하여 고객 경험을 개선합니다.