


컴퓨터비전 개론 2주차 요약본(5. 18.~5. 22.)

4. AI 기초: 신경망, 역전파(Backprop), 활성화 함수

4.1 AI, 머신러닝(ML), 딥러닝(DL) 개요

- **AI (Artificial Intelligence, 인공지능)**
 - 인간의 사고를 모방하는 기술
 - 규칙 기반 시스템부터 최신 딥러닝 모델까지 포함
- **ML (Machine Learning, 머신러닝)**
 - AI의 하위 분야로, 데이터를 이용해 패턴을 학습하고 예측하는 기술
 - 지도학습, 비지도학습, 강화학습 등의 방법 포함
- **DL (Deep Learning, 딥러닝)**
 - 머신러닝의 한 분야로, 다층 신경망(Neural Network)을 이용한 학습 기법
 - 데이터 양이 많을수록 성능이 향상됨
- 머신러닝의 종류
 - 지도학습(Supervised Learning)
 - 문제와 정답 모두 알려주고 학습 → 예측(prediction), 분류(Classification)
 - 비지도 학습(Unsupervised Learning)
 - 답을 가르쳐주지 않고 공부시키는 방법 → 연관성 파악, 군집(Clustering)
 - 강화 학습(Reinforcement Learning)
 - 보상을 통해 상은 최대화, 벌은 최소화하는 방향으로 행위를 강화하는 학습 → 보상
- 머신러닝과 딥러닝 비교
 - 머신러닝(ML)은 특징을 사람이 직접 추출해야 함
 - 딥러닝(DL)은 특징 추출 과정도 신경망이 자동으로 수행



- 데이터 세트
 - **훈련 데이터 (Training Data)** : 모델을 학습시키는 데 사용하는 데이터
 - **검증 데이터 (Validation Data)** : 학습 중 모델의 성능을 점검하는 데이터
 - **테스트 데이터 (Test Data)** : 최종 모델의 성능을 평가하는 데이터
- 모델 성능 평가 지표
 - 회귀

지표	의미	특징
MAE (Mean Absolute Error)	실제값과 예측값의 절대값 오차의 평균	모든 오차를 동일하게 취급, 해석이 직관적
RMSE (Root Mean Squared Error)	오차 제곱의 평균에 제곱근을 취한 값	큰 오차에 더 민감, 이상치 영향 큼
R² (결정계수)	모델이 데이터를 얼마나 잘 설명하는가를 나타냄	1에 가까울수록 설명력이 높음, 0 이하는 매우 부적합

- 분류

지표	의미	계산식/특징
정확도 (Accuracy)	전체 중 맞게 예측한 비율	$(TP + TN) / (TP + TN + FP + FN)$
정밀도 (Precision)	모델이 '양성'이라고 예측한 것 중 실제로 양성인 비율	$TP / (TP + FP)$

지표	의미	계산식/특징
재현율 (Recall)	실제 양성 중 모델이 '양성'이라고 맞춘 비율	$TP / (TP + FN)$
F1-score	정밀도와 재현율의 조화평균	$2 \times (Precision \times Recall) / (Precision + Recall)$
ROC-AUC (Area Under Curve)	분류 임계값에 따라 성능을 평가한 곡선의 면적	1에 가까울수록 좋음, 클래스 불균형에도 강함

4.2 선형회귀와 경사 하강법

- 선형 회귀 (Linear Regression)
 - 입력 x 와 출력 y 의 관계를 직선으로 모델링
 - 수식 : $y = wx + b$
- 경사 하강법 (Gradient Descent)
 - 손실 함수를 가장 작게 만드는 방향으로 w , b 를 반복 조정

4.3 신경망과 퍼셉트론(Perceptron)

- 신경세포와 퍼셉트론
 - 인공 뉴런(Perceptron)은 생물학적 신경세포를 모방하여 개발됨
 - 뉴런이 여러 개 연결되어 네트워크를 형성하면 딥러닝 모델이 됨
- 퍼셉트론 구조
 - 입력층(Input layer) → 가중치(Weight)와 바이어스(Bias) 적용 → 활성화 함수(Activation Function) → 출력층(Output layer)

4.4 XOR 문제와 다층 신경망

- 퍼셉트론의 한계
 - 단층 퍼셉트론은 선형 분리가 가능한 문제만 해결 가능
 - XOR 문제는 단층 퍼셉트론으로 해결할 수 없음
- 다층 신경망(MLP, Multi-Layer Perceptron)
 - 은닉층(Hidden Layer)을 추가하여 XOR 문제 해결 가능
 - 입력층 → 은닉층 → 출력층 구조를 가짐

4.5 신경망 학습과 오류 역전파 (Backpropagation)


- **신경망 학습 과정**
 - **순전파(Forward Propagation)**
 - 입력 데이터를 신경망을 통해 전달하여 예측값 출력
 - **손실 함수(Loss Function) 계산**
 - 예측값과 실제값의 차이를 계산
 - **역전파(Backpropagation)**
 - 손실을 최소화하기 위해 가중치와 바이어스를 조정
 - 체인 룰(Chain Rule)을 이용하여 미분
 - **가중치 업데이트**
 - 경사 하강법(Gradient Descent) 또는 Adam 옵티마이저(Optimizer)로 최적화 수행
- **기울기 소실(Vanishing Gradient) 문제**
 - **문제 발생 원인**
 - 역전파 과정에서 기울기(Gradient)가 점점 작아져서 학습이 제대로 진행되지 않는 현상
 - 주로 시그모이드 함수나 tanh 함수에서 발생
 - **해결 방법**
 - ReLU(Rectified Linear Unit) 활성화 함수 사용
 - 가중치 초기화 방법 개선 (Xavier, He Initialization 등)
 - Batch Normalization 사용

4.6 활성화 함수(Activation Function)

- 인공신경망에서 입력 신호를 비선형적으로 변환해 다음 층으로 전달하는 함수로, 모델이 복잡한 패턴을 학습할 수 있게 해준다.
- **Sigmoid**

$$\delta(x) = \frac{1}{1 + e^x}$$

- 출력 값을 0에서 1
- 가장 오래된 함수
- Saturation (기울기 소실)
- Not zero-centered




→ 출력값이 (0,1) 사이, 기울기 소실 문제 발생 가능

• Tanh

$$\delta(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$


- 출력 값은 -1에서 1
- Still Saturation
- Zero-centered



• ReLU

$$\delta(x) = \max(0, x)$$

- 출력 값을 0에서 ∞
- 계산 효율이 뛰어남. sigmoid보다 훨씬 빠름
- 양의 구간에서 Not Saturated




→ 기울기 소실 문제 해결, 빠르고 효율적

• Leaky ReLU

$$\delta(x) = \begin{cases} x, & \text{if } x \geq 0 \\ ax, & \text{else} \end{cases}$$

- 음수구간에서 0이 아님
- 계산 효율이 뛰어남. sigmoid보다 훨씬 빠름
- Not Saturated



→ ReLU의 문제 해결, 음수 구간에서도 기울기 존재

4.7 최적화 함수 (Optimizer)

- 신경망의 가중치(weight)를 업데이트하여 손실(loss)을 최소화하는 알고리즘

Optimizer	특징
SGD (Stochastic Gradient Descent)	기본 형태의 경사 하강법. 단순하지만 수렴 속도가 느릴 수 있음
Momentum	이전 이동 방향을 고려해 진동을 줄이고 빠른 수렴을 유도
AdaGrad	학습률을 변수마다 다르게 조정. 드물게 등장하는 변수에 더 큰 학습률 부여
RMSProp	AdaGrad의 단점을 보완. 최근 기울기에 가중치를 두어 학습률 감소 문제 해결
Adam (Adaptive Moment Estimation)	Momentum + RMSProp 결합형. 가장 널리 사용되는 최적화 알고리즘
AdamW	Adam에 정규화(weight decay)를 추가해 과적합 방지

5. 인공지능 학습: 경사하강법(GD)의 구현

5.1 합성 함수

- 합성 함수란?
 - 두 함수 $f(x)$ 와 $g(x)$ 가 있을 때, 한 함수의 출력값을 다른 함수의 입력값으로 사용하는 방식
 - 수학적 표현 및 예제

$$h(x) = f(g(x))$$

$$f(x) = 2x + 3, \quad g(x) = x^2$$

$$z(x) = f(g(x)) = 2x^2 + 3$$

- 딥러닝에서는 여러 개의 층을 쌓아, 합성 함수를 구성하여 복잡한 문제를 해결

5.2 경사 하강법(Gradient Descent)

• 경사 하강법이란?

- 머신러닝 및 최적화 문제에서 널리 사용되는 알고리즘
- 비용 함수(Loss Function)를 최소화하는 방향으로 가중치를 업데이트
- 신경망 학습 과정에서 필수적인 최적화 기법

• 경사 하강법의 단계

1. 초기값 설정: 파라미터(가중치)를 임의로 초기화
2. 기울기 계산: 현재 위치에서 함수의 기울기(미분값)를 계산
3. 파라미터 업데이트: 기울기의 반대 방향으로 이동하여 최적값을 찾음
4. 반복: 수렴할 때까지 위 과정을 반복

$$\theta_{n+1} = \theta_n - \alpha \nabla_{\theta} J(\theta_n)$$

θ : 파라미터 (예: 가중치).

α : 학습률 (learning rate).

$\nabla_{\theta} J(\theta)$: 비용 함수 $J(\theta)$ 의 기울기.

• 경사 하강법의 원리

→ 기울기 방향을 따라 내려가면서 손실을 줄이는 과정

• 학습률 (lr: Learning Rate)

- 학습률 α 값이 너무 크면 **Overshooting** (최적점을 지나침) 발생

- 학습률 α 값이 너무 작으면 수렴 속도가 느려짐

• 경사 하강법의 종류

◦ 배치 경사 하강법 (Batch Gradient Descent)

- 전체 훈련 데이터를 한 번에 사용하여 기울기를 계산
- 장점: 전체 데이터를 사용하여 안정적인 학습 가능
- 단점: 데이터가 많을 경우 계산 비용이 큼

◦ 확률적 경사 하강법 (Stochastic Gradient Descent, SGD)

- 훈련 데이터에서 하나의 샘플을 랜덤하게 선택하여 기울기를 계산
- 장점: 계산 속도가 빠르고, 메모리 요구량이 적음
- 단점: 매 스텝마다 최적화 방향이 바뀌어 학습이 불안정할 수 있음

◦ 미니배치 경사 하강법 (Mini-batch Gradient Descent)

- 훈련 데이터를 작은 배치 단위로 나누어 각 배치에서 기울기를 계산
- 장점: 배치 경사 하강법의 안정성과 SGD의 속도를 조합
- 단점: 배치 크기 선택에 따라 성능이 달라질 수 있음

5.3 학습 순서

단계	내용	PyTorch 예시 코드
1. 예측	입력을 모델에 넣어 예측값 계산	<code>outputs = net(inputs)</code>
2. 손실 계산	예측값과 실제값 비교	<code>loss = criterion(outputs, labels)</code>
3. 역전파	손실에 따른 기울기 계산	<code>loss.backward()</code>
4. 최적화	가중치 업데이트	<code>optimizer.step()</code>

5.4 학습 스케줄러

• 스케줄러의 종류

스케줄러	특징
StepLR	일정 에폭마다 학습률을 일정 비율로 감소시킴
ExponentialLR	학습률을 매 스텝마다 지수적으로 감소시킴

스케줄러	특징
MultiStepLR	특정 에폭 구간마다 감소시킴
CosineAnnealingLR	학습률을 코사인 곡선 형태로 감소시켜 부드럽게 수렴
ReduceLROnPlateau	손실이 일정 기간 개선되지 않을 때 학습률을 줄임 (적응형 방식)
OneCycleLR	학습 중 학습률을 증가 후 감소시키는 전략 (빠른 수렴에 효과적)

- **너무 큰 학습률:** 발산하거나 최소점을 지나침
- **너무 작은 학습률:** 학습 속도 느림, 지역 최소점에 머무를 수 있음

5.5 배치 (Batch)

- 배치는 한 번에 모델에 넣어 학습시키는 데이터 묶음이다.
- 전체 데이터를 한 번에 학습시키지 않고, 여러 묶음으로 나누어 처리한다.
- Full Batch (전체 배치 학습)
 - 한 번의 학습(가중치 업데이트)에 전체 데이터셋을 모두 사용
- Mini Batch (미니배치 학습)
 - 데이터를 작은 묶음(예: 32, 64개 등)으로 나누어 학습
- 배치 정규화 (Batch Normalization)
 - 배치 단위로 데이터를 정규화하여 학습 안정성과 속도를 높이는 기법
 - 내부 공변량 변화(Internal Covariate Shift)를 줄이는 데 도움을 줌

6. 손실함수 정의(Loss Function)

6.1 손실함수 (Loss Function)

- **비용 함수(Cost Function) :** 전체 데이터(또는 배치)에 대한 평균 오차를 계산하는 함수
- **손실 함수란(Loss Function) :** 모델이 예측한 값과 실제 정답 간의 차이를 수치로 표현한 함수

6.2 손실 함수의 종류

- **회귀 예측(Regression)**
 - 지도학습(Supervised Learning)의 한 종류

- 목표값(타겟, Target)이 연속적인 값을 가지는 경우 사용
- MSE(Mean Squared Error, 평균 제곱 오차) 사용
- 예: 집값 예측, 수율 예측, 혈압 예측 등

• 이진 분류(Binary Classification)

- 지도학습 방식
- 목표값이 두 개의 클래스로 나뉘는 경우
- 활성화 함수로 Sigmoid(시그모이드) 사용
- 출력값을 0과 1 사이로 변환하여 확률값으로 해석 가능
- Binary Crossentropy 사용
- 예: 종양(악성/양성) 판별, 스팸 메일, 시험 결과(P/F) 등

• 다중 분류(Multinomial Classification)

- 목표값이 3개 이상의 클래스로 나뉘는 경우
- 활성화 함수로 Softmax 사용
- 각 클래스에 대한 확률값을 계산하여 총합이 1이 되도록 정규화
- Crossentropy (Categorical Crossentropy) 사용
- 예: 붓꽃의 종류(Setosa / Versicolor / Virginica), 성적 등급 산출(A~F) 등

6.3 클래스 불균형

- 분류 문제에서 각 클래스의 데이터 개수가 크게 차이 나는 상황을 의미함.
 - 예: 스팸 메일 5%, 정상 메일 95%

구분	방법	적용 단계	핵심 아이디어
가중치 손실 (Weighted Cross Entropy)	Weighted CE	모델 학습 시	클래스별 손실 가중치를 다르게 부여하여 소수 클래스에 더 큰 비중을 줌
과샘플링 (Over-sampling)	Random Over-sampling	데이터 전처리	소수 클래스 데이터를 복제하거나 늘려 데이터 비율을 맞춤
언더샘플링 (Under-sampling)	Random Under-sampling	데이터 전처리	다수 클래스 데이터를 줄여 클래스 비율을 맞춤

구분	방법	적용 단계	핵심 아이디어
SMOTE	Synthetic Minority Over-sampling Technique	데이터 전처리	소수 클래스 데이터를 기존 샘플을 바탕으로 합성하여 생성
포컬 로스 (Focal Loss)	Focal Loss	모델 학습 시	어려운 샘플에 더 집중하도록 손실 함수를 조정

7. 선형 회귀(Linear Regression)

7.1 선형 회귀

- 개념
 - 지도학습(Supervised Learning)의 한 종류
 - 목표값(반응변수, Dependent Variable)이 연속형인 경우 사용
 - 입력 변수(Feature)가 하나일 경우 단순 회귀(Simple Regression)
 - 입력 변수가 여러 개일 경우 다중 회귀(Multiple Regression)

- 선형 회귀 모델

$$y = \beta_0 + \beta_1 x + \epsilon$$

- y: 종속 변수(목표값)
- x: 독립 변수(입력값)
- β_0 : 절편(intercept)
- β_1 : 기울기(slope)
- ϵ (epsilon): 오차(error term)


7.2 최소제곱추정량 (OLS, Ordinary Least Squares Estimation)

- 최소제곱법의 개념
 - 회귀선이 데이터를 가장 잘 표현하도록 가중치를 찾는 방법
 - 오차(Residual, 실제값 - 예측값)의 제곱합을 최소화하는 방식
 - 오차의 제곱을 최소화하는 방식으로 최적의 회귀선을 찾음
 - 경사 하강법(Gradient Descent) 또는 행렬 연산을 이용하여 최적화 가능

7.3 다항 회귀(Polynomial Regression)

• 다항 회귀란?

- 독립 변수의 차수가 2차 이상인 회귀 모델
- 비선형 관계(Non-Linear Relationship)를 모델링 할 때 사용
- 단순 선형 회귀와 달리 비선형 관계를 설명 가능
- 변수의 차수를 증가시키면, 보다 복잡한 패턴을 모델링 할 수 있음




8. 이진 분류(Binary Classification)

8.1 이진 분류 모델 구조

• 기본 구조


- 입력층 (Input Layer) → 가중치(W) 및 활성화 함수(Activation Function) → 출력층 (Output Layer)
- 출력층에서는 확률 값을 기반으로 이진 분류 수행



• 결정 경계 (Hyperplane)

- 데이터를 두 개의 클래스로 구분하는 경계를 의미
- 선형 모델에서는 직선(2D) 또는 평면(3D)으로 결정 경계를 형성


결정 경계 구하기 (Hyperplane)



8.2 훈련 데이터셋과 검증&평가 데이터셋

• 데이터셋 분할

- 학습 데이터 (Training Set): 모델을 학습하는 데 사용
- 검증 데이터 (Validation Set): 하이퍼파라미터(Hyper Parameter) 최적화를 위한 데이터
- 테스트 데이터 (Testing Set): 모델 성능을 평가하는 데 사용



8.3 모델 평가 방법

- 교차 검증 (Cross Validation)
 - 데이터셋을 여러 개의 부분으로 나누어 여러 번 학습 및 평가를 수행
 - k-fold 교차 검증이 대표적인 방법
- 부트스트래핑 (Bootstrapping)
 - 데이터의 일부를 샘플링하여 여러 개의 학습 데이터셋을 생성하는 방법
 - 데이터가 적을 때 유용

8.4 모델 평가 지표

1. 정확도 (Accuracy)

$$ACC = \frac{TP + TN}{TP + TN + FP + FN}$$

전체 데이터 중에서 올바르게 분류된 샘플의 비율.

2. 정밀도 (Precision)

$$Precision = \frac{TP}{TP + FP}$$

모델이 양성(Positive)으로 예측한 것 중 실제 양성인 비율.

예제: 스팸 필터 → 거짓 양성(False Positive)이 중요한 경우.

3. 재현율 (Recall, Sensitivity)

$$Recall = \frac{TP}{TP + FN}$$

실제 양성(Positive) 데이터 중 모델이 올바르게 예측한 비율.

예제: 암 진단 → 거짓 음성(False Negative)이 중요한 경우.

4. F1-점수 (F1-Score)

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$$

정밀도(Precision)와 재현율(Recall)의 조화 평균.

8.5 혼동 행렬 (Confusion Matrix)

	Positive Predicted (P)	Negative Predicted (N)
Positive Actual(P)	True Positive (TP)	False Negative (FN)
Negative Actual(N)	False Positive (FP)	True Negative (TN)

- **True Positive (TP):** 실제 양성을 양성으로 예측
- **False Positive (FP):** 실제 음성을 양성으로 예측 (거짓 양성)
- **False Negative (FN):** 실제 양성을 음성으로 예측 (거짓 음성)
- **True Negative (TN):** 실제 음성을 음성으로 예측


8.6 평가 지표 선택 기준

평가 지표	중점 사항	예시
정밀도(Precision)	거짓 양성(FP)을 줄이는 것이 중요할 때	스팸 필터, 광고 클릭 예측
재현율(Recall)	거짓 음성(FN)을 줄이는 것이 중요할 때	암 진단, 사기 탐지
F-1 Score	정밀도와 재현율이 모두 중요한 경우	일반적인 이진 분류 문제
ROC-AUC	확률 기반 모델의 전체적인 성능 평가	다양한 확률 분류 문제

8.7 ROC-AUC (Receiver Operating Characteristic - Area Under Curve)

- 확률 기반 모델의 전반적인 분류 능력을 평가하는 지표
- AUC 값이 1에 가까울수록 모델 성능이 좋음

AUC



8.8 Pytorch 학습 과정의 핵심 단계

```
# 1. 경사값 초기화
optimizer.zero_grad()          # 이전 단계의 gradient 초기화

# 2. 순전파
outputs = model(inputs)        # 모델에 입력 → 예측값 계산

# 3. 손실 계산
loss = criterion(outputs, labels) # 예측값과 실제값 비교

# 4. 역전파
loss.backward()                # 각 파라미터의 gradient 계산

# 5. 파라미터 업데이트
optimizer.step()               # 경사를 이용해 파라미터 업데이트
```